

AWS Certified AI Practitioner (AIF-C01) - Guia

Autor: Felipe Caetano

Objetivo: Domínio teórico e prático de todos os conceitos cobrados no exame, detalhando diferenças sutis entre serviços, casos de uso reais e decisões de arquitetura na nuvem AWS.


SUMÁRIO DE MÓDULOS

1. [Módulo 1: Fundamentos de Machine Learning e Deep Learning](#)
2. [Módulo 2: Fundamentos de IA Generativa e Modelos de Base](#)
3. [Módulo 3: Amazon Bedrock e Ecossistema de IA Generativa](#)
4. [Módulo 4: Amazon Q e Serviços de IA Especializados da AWS](#)
5. [Módulo 5: IA Responsável, Governança e Métricas de Avaliação](#)
6. [Módulo 6: Segurança, Redes VPC, Compliance e Gestão de Custos](#)

MÓDULO 1: Fundamentos de Machine Learning e Deep Learning

1.1 Paradigmas de Aprendizado de Máquina

A prova exige o entendimento preciso das quatro categorias principais de aprendizado:



- **Aprendizado Supervisionado (Supervised Learning):**

- **Teoria:** O modelo aprende a partir de dados históricos **rotulados** (entradas com saídas conhecidas / *ground truth*).
- **Tarefas:**
 - **Classificação:** Prever rótulos categóricos discretos (ex: "Fraude" vs "Legítima", "Spam" vs "Não Spam").
 - **Regressão:** Prever valores numéricos contínuos (ex: preço de imóveis, demanda de estoque, variação de temperatura).
- **Algoritmos Notáveis:** Regressão Linear/Logística, K-Nearest Neighbors (K-NN), Árvores de Decisão, Random Forest, XGBoost.
- **Aprendizado Não Supervisionado (Unsupervised Learning):**
 - **Teoria:** O modelo processa dados **não rotulados** para descobrir estruturas, padrões ou agrupamentos implícitos.
 - **Tarefas:**
 - **Clustering (Agrupamento):** Separação de instâncias em grupos homogêneos (ex: segmentação de perfil de clientes por comportamento de compra usando K-Means).
 - **Redução de Dimensionalidade:** Compressão de variáveis mantendo a variância (ex: PCA - Principal Component Analysis).
 - **Deteção de Anomalias:** Identificação de desvios em relação à distribuição padrão.
- **Aprendizado por Reforço (Reinforcement Learning - RL):**
 - **Teoria:** Um **Agente** interage com um **Ambiente** dinâmico tomando **Ações** sequenciais para maximizar uma **Recompensa** acumulada (Reward) e evitar penalidades.
 - **Caso de Uso:** Otimização de rotas logísticas em tempo real, controle autônomo de robôs, trading financeiro automatizado, calibração de parâmetros operacionais industrial.
- **Deep Learning (Aprendizado Profundo):**
 - **Teoria:** Subcampo baseado em Redes Neurais Artificiais Profundas (múltiplas camadas ocultas) que realiza a **extração automática de hierarquias de atributos (Feature Extraction)** a partir de dados não estruturados (imagens, áudio, vídeos, texto denso), dispensando a engenharia de recursos manual necessária no ML

tradicional.

1.2 O Ciclo de Vida dos Dados e Engenharia de Atributos

- **Engenharia de Atributos (Feature Engineering):** Processo de selecionar, transformar, combinar e estruturar os dados brutos para alimentar os algoritmos de ML.
- **One-Hot Encoding:**
 - **Problema:** Algoritmos matemáticos de ML não conseguem operar diretamente com texto categórico (ex: Cores = ["Vermelho", "Azul", "Verde"]).
 - **Solução:** Transforma cada categoria em uma coluna binária (0 ou 1).
 - *Exemplo:*

Vermelho $\rightarrow [1, 0, 0]$

Azul $\rightarrow [0, 1, 0]$

Verde $\rightarrow [0, 0, 1]$

1.3 Diagnóstico de Performance: Overfitting vs. Underfitting

A prova cobra insistentemente como diagnosticar e corrigir problemas de generalização de modelos.

[Underfitting]	[Ideal]	[Overfitting]
Alto Viés (High Bias)		Alta Variância (High Variance)
Erro Alto no Treino e Teste	Erro Baixo no Treino e Teste	Erro Quase Zero no Treino
		Erro Gigante no Teste

Problema	Sintoma no Treino	Sintoma no Teste	Causa Raiz	Soluções Recomendadas
Overfitting (Sobreajuste)	Erro insignificante (0)	Erro extremamente elevado	O modelo "memorizou" o ruído e particularidade	1. Aplicar técnicas de Regularização (

			s dos dados de treino.	$L1/L2$. 2. Adicionar camadas de <i>Dropout</i> em redes neurais. 3. Coletar mais dados de treino. 4. Reduzir a complexidade do modelo (menos parâmetros).
Underfitting (Subajuste)	Erro elevado	Erro elevado	O modelo é simples demais para capturar a complexidade do problema.	1. Aumentar a complexidade do algoritmo. 2. Adicionar novos atributos (Feature Engineering). 3. Reduzir as restrições de regularização.

MÓDULO 2: Fundamentos de IA Generativa e Modelos de Base

2.1 Conceitos Essenciais e Arquitetura


- **Foundation Models (FMs):** Modelos massivos de Deep Learning treinados em conjuntos gigantescos de dados não estruturados usando aprendizado auto-supervisionado. Atuam como base flexível para diversas tarefas operacionais sem necessidade de retreinamento do zero.
- **Janela de Contexto (Context Window):** O limite máximo de tokens (somatório de texto

de entrada e saída) que o modelo consegue manter em sua "memória de trabalho" durante uma única chamada de inferência.

- *Atenção para o exame:* Se um prompt exceder a Janela de Contexto, ocorrerá o truncamento de informações (*Context Truncation*), levando à perda de partes cruciais do documento ou instrução.

2.2 Hiperparâmetros de Inferência (Ajuste Fino de Saída)

Na AWS, você ajusta o comportamento do modelo via parâmetros de inferência no momento do envio do prompt.



1. Temperatura (Temperature):

- Controla a aleatoriedade da distribuição de probabilidade do próximo token.
- *Valores próximos de 0 (0.0 – 0.2):* Respostas altamente determinísticas, focadas, conservadoras e repetitivas (Ideal para extração de dados, código, suporte técnico e análise jurídica).
- *Valores altos (0.7 – 1.0):* Maior variação, criatividade e imprevisibilidade (Ideal para redação criativa, marketing e brainstorming).

2. Top P (Nucleus Sampling):

- O modelo ordena os tokens mais prováveis e seleciona apenas o menor conjunto cuja probabilidade cumulativa atinge o valor de P .
- *Exemplo:* $TopP = 0.9$ significa que o modelo considera apenas a fatia dos tokens principais que somam 90% de toda a probabilidade, ignorando os 10% com probabilidades muito baixas.

3. Top K:

- Limita a escolha do próximo token estritamente aos K tokens com maior probabilidade individual.
 - *Exemplo:* $TopK = 1$ (Greedy Decoding) obriga o modelo a escolher **sempre** a palavra mais provável da lista, tornando a saída extremamente determinística.
4. **Stop Sequences (Sequências de Parada):**
- Cadeias de caracteres especificadas pelo desenvolvedor (ex: \n, User:, ###). Quando o LLM gera esses caracteres na saída, o processamento de inferência é imediatamente interrompido.
 - *Uso Prático:* Impedir que um chatbot continue inventando as respostas fictícias do próprio usuário.

2.3 Representação Vetorial: Embeddings e Bancos Vetoriais

- **Embeddings:** Vetores numéricos de alta dimensão gerados por modelos especializados (ex: *Amazon Titan Text Embeddings*) que traduzem o significado semântico, contexto e relações conceituais de palavras, textos, áudios ou imagens.
- **Proximidade Semântica:** Textos com significados semelhantes geram vetores com pequena distância angular/euclidiana no espaço multidimensional.
- **Bancos de Dados Vetoriais Suportados na AWS:** Amazon OpenSearch Serverless, Amazon Aurora PostgreSQL (com extensão pgvector), Amazon DocumentDB, Pinecone, Redis Enterprise.

2.4 O Espectro de Customização de Modelos (Da Seleção à Customização Profunda)

A AWS cobra a escolha do método correto com base no trade-off de **Custo, Tempo, Volume de Dados e Latência**.

[Menor Custo / Sem Treino] —————> [Maior Custo / Treino Profundo]

Prompt Eng. —————> Few-Shot —————> RAG —————> PEFT/LoRA —————> Full
 Fine-Tuning —————> Pre-Training
 (Zero-Shot) (Exemplos) (Busca) (Adaptadores) (Todos os Pesos) (Do Zero)


1. **Prompt Engineering (Zero-Shot / Few-Shot):**
 - Nenhum peso do modelo é alterado. Injeta-se instruções ou alguns exemplos no contexto do prompt.
2. **Retrieval-Augmented Generation (RAG):**
 - **Conceito:** O modelo não é alterado. O conhecimento é recuperado de uma base de dados externa (S3 + Vector DB) no instante da pergunta e injetado dinamicamente no contexto enviado ao LLM.

- **Quando usar:** Dados atualizados frequentemente (diariamente/semanalmente), necessidade de citação exata da fonte de onde a informação veio e eliminação de alucinações.
- 3. **Parameter-Efficient Fine-Tuning (PEFT) / LoRA (Low-Rank Adaptation):**
 - **Conceito:** Congela os pesos originais do Foundation Model e insere pequenas matrizes treináveis em camadas específicas.
 - **Vantagem:** Reduz o uso de memória de GPU e os custos de treinamento em mais de 80% comparado ao Fine-Tuning completo, mantendo performance idêntica para a tarefa customizada.
- 4. **Full Fine-Tuning:**
 - Ajusta **todos** os parâmetros e pesos da rede neural usando um dataset rotulado do domínio específico. Alto custo computacional de GPUs.
- 5. **Continued Pre-training:**
 - Treina o modelo com dados não rotulados gigantescos de um domínio extremamente especializado (ex: medicina genômica avançada) antes do fine-tuning.

MÓDULO 3: Amazon Bedrock e Ecossistema de IA Generativa

3.1 Arquitetura e Recursos do Amazon Bedrock

O Amazon Bedrock é o serviço totalmente gerenciado *serverless* da AWS para criação de aplicações de IA Generativa via API unificada.



- **Acesso a Modelos (Model Access):** Por razões de governança e segurança, os modelos no Bedrock vêm desabilitados por padrão. O administrador precisa acessar a página *Model Access* no console e solicitar a habilitação individual de cada modelo desejado.
- **Permissões Granulares via IAM:** Cada modelo possui um ARN (*Amazon Resource Name*)

único. O controle de acesso é feito via políticas IAM especificando o ARN do modelo no campo Resource:

arn:aws:bedrock:us-east-1::foundation-model/anthropic.claude-3-haiku-20240307-v1:0

3.2 Componentes do Amazon Bedrock Knowledge Bases (RAG Nativo)

Para implementar a arquitetura RAG no Bedrock sem gerenciar infraestrutura, são necessários obrigatoriamente **três componentes chave**:

1. **Fonte de Dados (Data Source):** Bucket no **Amazon S3** contendo os documentos originais (PDF, TXT, CSV, DOCX).
2. **Modelo de Embedding:** Modelo do Bedrock responsável pela conversão dos textos em vetores (ex: *Amazon Titan Text Embeddings v2*).
3. **Armazenamento Vetorial (Vector Store):** Base de dados para armazenar e indexar os embeddings.
 - Opção gerenciada padrão automática: **Amazon OpenSearch Serverless** (Vector Engine).
 - Alternativas suportadas: Amazon Aurora PostgreSQL (pgvector), Pinecone, Redis Enterprise.

3.3 Amazon Bedrock Agents (Agentes Autônomos)

- **O que faz:** Executa tarefas empresariais complexas de múltiplas etapas de forma autônoma.
- **Mecanismo de Funcionamento:**
 1. O agente quebra a solicitação do usuário em etapas lógicas (ReAct logic - Reasoning + Acting).
 2. Consulta Knowledge Bases se precisar de informações estruturadas.
 3. Invocação de Ações: Aciona funções **AWS Lambda** para executar chamadas de API em sistemas externos (ex: atualizar registro no CRM, cancelar pedido no ERP, enviar e-mail).

3.4 Outros Recursos do Bedrock

- **Provisioned Throughput (Capacidade Provisionada):** Garante taxa de transferência dedicada contratando *Model Units* sem variação de latência. Recomendado para aplicações de produção críticas e com volumetria constante.
- **Amazon Bedrock Studio:** Ambiente web colaborativo *no-code/low-code* onde equipes de negócios e desenvolvedores podem testar prompts, criar protótipos de agentes e Knowledge Bases utilizando login único corporativo (AWS IAM Identity Center).


MÓDULO 4: Amazon Q e Serviços de IA Especializados da AWS

4.1 O Grande Confronto: Amazon Q Business vs. Amazon Q Developer

vs. Amazon Kendra

Esta é uma das áreas com maior índice de pegadinhas no exame. A tabela a seguir estabelece as distinções fundamentais:

Funcionalidade / Critério	Amazon Q Business	Amazon Q Developer	Amazon Kendra
Categoria do Serviço	Assistente Conversacional Corporativo (IA Generativa).	Assistente de Desenvolvimento de Software e Operações AWS.	Mecanismo de Busca Vetorial/Inteligente Enterprise (Search Engine).
Público Principal	Usuários de negócios, RH, Vendas, Jurídico.	Desenvolvedores, Engenheiros DevOps, Arquitetos Cloud.	Aplicações que precisam apenas de busca e ranqueamento de documentos.
Saída Principal	Respostas sintetizadas em linguagem natural, resumos e execução de ações.	Geração de código, refatoração de código, diagnósticos de erros de AWS CLI/Console.	Trechos exatos de documentos (Passages) e FAQs relevantes ranqueados por relevância.
Controle de Acesso / Segurança	Aplica e respeita rigorosamente as ACLs nativas dos documentos via IAM Identity Center.	Integrado com credenciais IAM do desenvolvedor / Builder ID.	Aplica ACLs nativas nos resultados da pesquisa indexada.
Recurso Exclusivo	Amazon Q Apps: Criação de aplicativos web por prompt.	Code Transformation: Migração automatizada (ex: Java 8 para 17) e varredura de segurança de código.	Pesquisa por palavras-chave + pesquisa semântica com ajuste manual de relevância.



4.2 Serviços de IA Gerenciados/Pré-Treinados (Visão Geral)

Serviços que disponibilizam modelos pré-treinados prontos para consumo via API rest simples sem necessidade de construir modelos no SageMaker:

1. **Amazon Textract:** Extração inteligente de texto impresso, manuscrito, tabelas e dados estruturados de formulários e documentos PDF/imagens.
2. **Amazon Rekognition:** Análise de visão computacional (reconhecimento facial, detecção de objetos, moderação de conteúdo impróprio em vídeos/imagens).
3. **Amazon Comprehend:** Processamento de Linguagem Natural (NLP) para extração de entidades, detecção de idioma e **Análise de Sentimento** em textos.
4. **Amazon Transcribe:** Conversão de áudio/fala em texto (**Speech-to-Text**).
5. **Amazon Polly:** Conversão de texto em fala sintética humanizada (**Text-to-Speech**).
6. **Amazon Translate:** Tradução automática neural entre diversos idiomas.
7. **Amazon Personalize:** Mecanismo de recomendação personalizada em tempo real baseado nos algoritmos da Amazon.com.
8. **Amazon SageMaker Canvas:** Interface visual *no-code* que permite a analistas de negócios criar modelos de ML e fazer previsões sem escrever código.

MÓDULO 5: IA Responsável, Governança e Métricas de Avaliação

5.1 Princípios de IA Responsável e Desvios de Modelo

- **Transparência e Explicabilidade:** Habilidade de entender, explicar e auditar as razões pelas quais um modelo tomou uma decisão específica.

- **Variáveis Proxy (Proxy Variables / Implicit Bias):** Ocorre quando variáveis sensíveis protegidas (ex: Raça, Gênero) são removidas da base, mas o modelo continua discriminando porque utiliza atributos altamente correlacionados (ex: CEP de residência como proxy para etnia).
- **Alucinação (Hallucination):** Respostas geradas por LLMs que parecem altamente confiantes e convincentes, mas contêm fatos falsos ou inexistentes.
- **Contaminação de Dados (Data Contamination):** Vazamento inadvertido de dados do conjunto de teste/avaliação para dentro da base de treinamento do modelo, resultando em métricas de avaliação falsamente infladas.
- **Data Drift vs. Concept Drift:**
 - *Data Drift:* Mudança na distribuição estatística dos dados de entrada ao longo do tempo.
 - *Concept Drift:* Mudança na relação estatística entre os dados de entrada e a variável de saída prevista.
 - *Solução:* Monitoramento contínuo de modelos em produção e gatilhos automatizados para retreinamento.

5.2 Ferramentas AWS para Governança e Transparência

- **Amazon SageMaker Clarify:** Detecta viés (*bias*) nos dados de treinamento e modelos treinados, e fornece explicabilidade de modelos de ML usando valores **SHAP (Shapley Additive exPlanations)**.
- **Amazon SageMaker Model Cards:** Documentação padronizada e centralizada de metadados do modelo (propósito, dados de treinamento, métricas de avaliação, considerações éticas e auditoria de riscos).
- **AWS AI Service Cards:** Documentos públicos da AWS que detalham os limites, uso pretendido, métricas de performance e diretrizes de IA responsável dos serviços de IA pré-treinados gerenciados da AWS.

5.3 Métricas de Avaliação de Modelos (Essenciais para a Prova)

Métricas de Classificação

Para entender as métricas, considere a **Matriz de Confusão**:

	REALIDADE	
	Positivo	Negativo
P Positivo	[Verdadeiro]	[Falso]
R Negativo	[Positivo]	[Positivo]
E Negativo	[Falso]	[Verdadeiro]
I Positivo	[Negativo]	[Negativo]

1. **Precisão (Precision):** De tudo o que o modelo classificou como Positivo, quanto realmente era Positivo?

$$Precision = \frac{TP}{TP + FP}$$

2. **Revocação / Sensibilidade (Recall):** De tudo o que era REALMENTE Positivo no mundo real, quanto o modelo conseguiu capturar?

$$Recall = \frac{TP}{TP + FN}$$

3. **F1-Score:** Média harmônica entre Precisão e Recall.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Pegadinha da Prova: Em diagnósticos médicos de doenças graves, um **Falso Negativo (FN)** é o erro mais catastrófico (o paciente está doente, mas o modelo diz que está saudável). Nesses casos, busca-se otimizar o **Recall**.

Métricas de Regressão

- **RMSE (Root Mean Square Error):** Mede a magnitude do erro entre os valores contínuos previstos e reais.

Métricas de Avaliação de IA Generativa

- **ROUGE (Recall-Oriented Understudy for Gisting Evaluation):** Avalia a qualidade de resumos/sumarizações comparando a sobreposição de n-gramas entre o texto gerado e um resumo humano de referência.
- **BLEU (Bilingual Evaluation Understudy):** Avalia a qualidade de traduções de texto.


MÓDULO 6: Segurança, Redes VPC, Compliance e Gestão de Custos

6.1 Arquitetura de Rede VPC para Soluções Privadas de IA

Esta é a área crítica do exame. Quando uma aplicação exige que prompts e documentos **não transitem pela internet pública**:

[VPC do Cliente]

[Rede AWS]



1. VPC Interface Endpoints (alimentados pelo AWS PrivateLink):

- Aloca uma Interface de Rede Virtual (ENI) com IP privado diretamente dentro da sua Subnet Privada.
- Suportado por: **Amazon Bedrock, Amazon SageMaker, Amazon Q Business, AWS KMS.**
- *Uso:* Permite chamar APIs de IA a partir de redes privadas sem precisar de Internet Gateway ou NAT Gateway.

2. VPC Gateway Endpoints:

- **Recurso GRATUITO.**
- Existe **EXCLUSIVAMENTE** para dois serviços: **Amazon S3 e Amazon DynamoDB.**
- Adiciona uma rota direta na Route Table da subnet privada para acessar o S3 com segurança.

3. Componentes Proibidos em Arquiteturas de Extrema Privacidade:

- *Internet Gateway (IGW):* Expõe a subnet à internet pública.
- *NAT Gateway:* Utilizado para permitir saída para a internet a partir de subnets privadas (fatura tráfego de saída pela internet).

6.2 Proteção em Tempo Real com Amazon Bedrock Guardrails

O **Bedrock Guardrails** fornece salvaguardas programáveis aplicadas antes da entrada no modelo e após a geração da saída:

- **Denied Topics (Tópicos Negados):** Bloqueia conversas sobre assuntos não permitidos (ex: dar conselhos de investimento financeiro em um bot bancário).
- **Content Filters:** Bloqueia conteúdos de ódio, insultos, linguagem sexual ou violência.
- **Sensitive Information Filters (Filtros PII):** Identifica e **mascara** (ou bloqueia) dados pessoais (CPF, cartões de crédito, e-mails) em tempo real.
- **Contextual Grounding Check (Filtro de Alucinação):** Em soluções RAG, verifica se a resposta gerada está **estritamente fundamentada** nos documentos de contexto recuperados do S3. Se o modelo inventar algo que não está no documento, a resposta é bloqueada.
- **Ataques de Prompt Injection / Jailbreak:** O Guardrails detecta e neutraliza tentativas maliciosas de usuários de burlar as regras éticas do sistema.

6.3 Auditoria, Criptografia e Privacidade de Dados

- **Logging de Invocação de Modelos no Bedrock (Model Invocation Logging):** Registra todos os payloads de entrada (prompts), imagens, áudios e respostas enviando os dados para um bucket S3 ou grupo do CloudWatch Logs.
- **AWS CloudTrail:** Grava todas as chamadas de API executadas na conta AWS. Identifica *Quem, Quando* e *Qual* parâmetro foi enviado.
- **Amazon Macie:** Serviço que utiliza ML para varrer buckets Amazon S3 e descobrir/classificar automaticamente dados sensíveis expostos e PII.
- **Criptografia em Repouso:** Garantida através de integração com o **AWS KMS (Key Management Service)** usando *Customer Managed Keys (CMKs)* para criptografar volumes EBS do SageMaker, buckets S3 do RAG e logs de invocação.
- **Criptografia em Trânsito:** Obrigatoriamente executada via **HTTPS / TLS 1.2+.**
- **Garantia Absoluta de Privacidade no Amazon Bedrock:**
 - Os dados de entrada (prompts) e saídas do cliente **JAMAIS** são compartilhados com provedores de modelos de terceiros (Anthropic, Meta, Cohere, etc.).
 - Os dados do cliente **JAMAIS** são utilizados para treinar os modelos de base públicos da AWS ou de terceiros.

6.4 Governança Financeira e Gestão de Custos

- **AWS Budgets:** Permite criar orçamentos personalizados para rastrear os custos dos serviços de IA (Bedrock, SageMaker) e disparar alertas por e-mail/SNS ou acionar ações automáticas quando os custos previstos/reais ultrapassarem os limites.
- **AWS Organizations & Service Control Policies (SCPs):** Permite restringir centralmente o uso de instâncias de IA caras ou bloquear o acesso a regiões AWS específicas em múltiplas contas corporativas.
- **Modelo de Responsabilidade Compartilhada na IA Generativa:**
 - *Responsabilidade da AWS:* Segurança **DA** nuvem (infraestrutura física, hardware de aceleração/GPUs, isolamento de hypervisor do Bedrock, segurança dos modelos de base nativos).
 - *Responsabilidade do Cliente:* Segurança **NA** nuvem (dados de entrada/prompts, configuração de permissões IAM, criptografia dos dados, criação de Guardrails, uso adequado das respostas).

RESUMO DE DECISÃO RÁPIDA PARA A PROVA

Se o cenário da questão pedir:	A resposta correta DEVE ser:
Assistente de busca corporativo com controle de permissão por documento	Amazon Q Business + IAM Identity Center
Assistente de código na IDE / Migração de	Amazon Q Developer

versão Java / Scan de vulnerabilidade	
Busca vetorial indexada com ranqueamento sem IA conversacional	Amazon Kendra
Conexão privada de instâncias EC2 ao Bedrock sem internet	VPC Interface Endpoint (AWS PrivateLink)
Conexão privada gratuita para leitura de arquivos no S3	VPC Gateway Endpoint
Evitar alucinações no Bedrock RAG com verificação na fonte	Bedrock Guardrails (Contextual Grounding Check)
Detectar viés e explicabilidade com valores SHAP	Amazon SageMaker Clarify
Varrer e mascarar PII em buckets S3 antes de treinar ML	Amazon Macie
Customizar modelo com baixo custo mantendo pesos congelados	PEFT / LoRA
Documentação e governança formal de um modelo customizado	Amazon SageMaker Model Cards

Geramos o relatório de estudos em formato Markdown.

Destaques do Relatório de Estudos:

1. **Mapeamento Completo do Simulado:** Todos os conceitos abordados nas 65 questões do simulado estão organizados sistematicamente em 6 módulos técnicos.
2. **Didática e Comparações de Arquitetura:**
 - Tabelas comparativas detalhadas entre **Amazon Q Business vs. Q Developer vs. Amazon Kendra**.
 - Diagramas textuais do fluxo de rede **VPC (Interface Endpoints/PrivateLink vs. Gateway Endpoints)**.
 - O espectro de customização de modelos (da engenharia de prompt ao RAG, PEFT/LoRA e Fine-Tuning completo).
3. **Foco nas Pegadinhas Clássicas:** Explicações claras sobre as métricas de IA/ML, o funcionamento do Bedrock Guardrails, a atuação do SageMaker Clarify e a gestão de compliance no Modelo de Responsabilidade Compartilhada da AWS.
4. **Tabela de Decisão Rápida:** Um resumo prático no final do documento ligando os enunciados clássicos de prova às respostas corretas na AWS.

Bons estudos! Com este material e o simulado praticado, seu domínio técnico sobre os gargalos do exame está solidificado para a aprovação no dia 15!